

Shannon Entropy (정보량과 불확실성의 상관관계)

요점 : 불확실성이 높을수록 많은 정보량을 얻게 된다

Shannon Entropy : 정보량을 측정하는 대표적인 방법

$$H(X) = - \sum_{i=1}^n p_i \log_2 p_i = \sum_{i=1}^n (\log_2 \frac{1}{p_i}) p_i$$

기대값 공식 : $E[X] = \sum_{i=1}^k x_i p_i$

엔트로피 공식 : $H(X) = \sum_{i=1}^n \log_2 \frac{1}{p_i} p_i \rightarrow$ "정보량의 기댓값"을 의미함

$\log_2 \frac{1}{p_i}$ 가 정보량을 의미하는 이유

$H(X) = \sum_{i=1}^n I(x_i) \times p_i$, $I(x_i)$ 는 x_i 의 정보량을 계산하는 함수라고 가정하고 다음 두 조건을 생각해 보자

1. The more uncertain an event is, the more information it carries : 불확실성이 높을수록 많은 정보량을 가지게 된다

$$p(x_1) > p(x_2) \rightarrow I(x_1) < I(x_2)$$

즉, x_1 보다 x_2 의 불확실성이 더 크기 때문에 x_2 의 정보량이 더 크다.

이 때 $I(x)$ 를 $\frac{1}{p(x)}$ 라고 정의하면 확률이 높을수록 정보량이 작아지기에

$p(x_1) > p(x_2) \rightarrow I(x_1) < I(x_2)$ 를 만족함

2. If x_1 and x_2 are independent events, $I(x_1, x_2) = I(x_1) + I(x_2)$

\log 를 이용하게 되면 $\log A \times B$ 를 $\log A + \log B$ 로 계산 가능함. ($\log A \times B = \log A + \log B$)

so, $I(x) = \log(\frac{1}{p(x)})$

log의 base가 왜 2인가

이용하고자 하는 정보량을 bit의 수로 나타낼 수 있기 때문

ex) what is the max entropy for random variable has 4 different result?

$$0 \leq \sum_{i=1}^n \log_2 \frac{1}{p_i} * p_i \leq 2$$

위 수식 중 2는 4개($4 = 2^2$)의 랜덤변수의 정보량을 저장하는데 필요한 bit의 갯수를 의미한다.

- 최대 엔트로피가 $\log_2 n$ 이 되는 이유
엔트로피가 최대값이 되기 위해선 n 개의 random variable의 모든 확률이 $\frac{1}{n}$ 이어야 한다.
so, 최대 엔트로피는 $\sum_{i=1}^n \log_2 \frac{1}{n} \times \frac{1}{n} = \log_2 \frac{1}{n} \times \frac{1}{n} \times n = \log_2 \frac{1}{n} = \log_2 n$ 로 유도된다.

출처 : <https://www.youtube.com/watch?v=CdH7U3JjRI8&list=PLVNY1HnUIO241gLgQloWAs0xrrkqQfKe&index=51>